

APLICACIÓN DE REDES NEURONALES ARTIFICIALES A LA PREDICCIÓN DEL ÉXITO DE PROYECTOS TIC

APPLICATION OF ARTIFICIAL NEURAL NETWORKS TO ANTICIPATE THE SUCCESS OF ICT PROJECTS

Mary Luz Mouronte-López

Department of Computer Science. Higher Polytechnic School. Universidad Francisco de Vitoria. Ctra. Pozuelo a Majadahonda
Km 1.800, Pozuelo de Alarcón, 28223 Madrid,Recibido: 23/Sep/19 – Revisando: 8/Oct/19 - Aceptado: 29/Ene/20 - DOI: <https://doi.org/10.6036/NT9425>

TO CITE THIS ARTICLE:

MOURONTE-LÓPEZ, Mary Luz. APPLICATION OF ARTIFICIAL NEURAL NETWORKS TO ANTICIPATE THE SUCCESS OF
ICT PROJECTS. DYNA New Technologies, Enero-Diciembre 2020, vol. 7, no. 1, p.[20]. DOI: <http://doi.org/10.6036/NT9425>**ABSTRACT:**

This research shows that the use of neural networks can help to predict the success of projects in a large ITC company, improving their business outcomes and its sales process. The research was carried out in a company with an annual average of 72,350 ended projects, which were managed using different methodologies. Data related to a period of 9 years were used. A successful project, according to the company's guidelines were those that had 0 unplanned impacts, a maximum deviation of 4% over the estimated budget, a maximum deviation of 2 weeks from the expected end date and a evaluation by the customer in the range [7, 10]. These variables were calculated separately using 4 RNA.

As a neural network model, a High-Order Multi-Layer Perceptron (MLP) was used, wich had 1 input layer with 16 nodes, 3 hidden layers with 11 nodes and 1 output layer with a node, as well as with Sigmoid, Rectified Linear Unit, Hyperbolic Tangent, and Arc-hyperbolic sine activation functions in the hidden layers. The activation function used in the input and output layers was the Sigmoid function. According to the established requirements, the RNA should achieve a Mean Square Error (MSE) of less than 0.00025 and a training time of less than 1.50 hours, with a learning rate of less than 0.1. Several sizes of the training set were selected in order to carry out 145 experiments with each activation function and training set. The best results were achieved using the Rectified Linear Unit activation function in the hidden layers, which achieved the goals for the four variables. The solution was deployed in an operational environment for one year, an increase in the percentage of projects that met the success goals was achieved. A survey was filled out by all the people related to the solution and involved in the sales process, obtaining an average score of 9.2. The questions were scored between 1 (worst value) and 10 (best value)

Keywords: Neural Networks, TIC projects, Sales Process, success prediction, business results

RESUMEN:

Esta investigación demuestra que el uso de redes neuronales artificiales (RNA) puede ayudar a predecir el éxito de los proyectos candidatos a ser ejecutados en una gran compañía del sector TIC, a mejorar los resultados del negocio y a optimizar el proceso de ventas. El trabajo se llevó a cabo en una compañía con una media anual de 72.350 proyectos finalizados, los cuales fueron gestionados utilizando diversas metodologías. Específicamente se utilizaron datos de proyectos terminados a lo largo de 9 años. Un proyecto exitoso, conforme a las directrices de la compañía, era aquel que tenía una ocurrencia de 0 impactos no planificados, una desviación máxima de 4% sobre el presupuesto estimado, un desvío máximo de 2 semanas sobre la fecha final prevista y una evaluación por parte del cliente en el rango [7,10]. Estas variables fueron calculadas por separado utilizando 4 RNA.

Cada RNA que se empleó fue una High-Order Multi-Layer Perceptron (MLP) con una capa de entrada con 16 nodos, 3 capas ocultas con 11 nodos y una capa de salida con un nodo, así como funciones de activación en las capas ocultas: Sigmoid, Rectified Linear Unit, Hyperbolic Tangent, y Arc-hyperbolic sine. La función de activación utilizada en la capas de entrada y salida fue la función Sigmoid. Según los requerimientos establecidos la RNA debía conseguir un Mean Square Error (MSE) inferior a 0,00025 y un tiempo de entrenamiento menor a 1,50 horas, con una tasa de aprendizaje inferior a 0,1. Se seleccionaron varios tamaños del conjunto de entrenamiento, llevando a cabo para cada tamaño y función de activación 145 experimentos. Los mejores resultados fueron logrados empleando la función de activación Rectified Linear Unit en las capas ocultas, que consiguió cumplir los objetivos establecidos para las cuatro variables. La solución se puso en funcionamiento en un entorno operacional durante un año, obteniéndose un aumento en el porcentaje de proyectos que cumplieron los criterios de éxito. Una encuesta rellena por todas las personas relacionadas con la solución e involucradas en el proceso de ventas obtuvo una puntuación media de 9,2. Las preguntas eran puntuables entre 1 (el peor valor) y 10 (el mejor valor).

Palabras clave: Redes neuronales, proyectos TIC, proceso de ventas, predicción de éxito, resultados de negocio

1.- INTRODUCCION

Esta investigación está motivada por la necesidad de mejorar los resultados del negocio de una gran compañía multinacional del sector de Tecnologías de Información y Comunicación (TIC). Se demuestra que el uso de Redes Neuronales Artificiales (RNA) puede ayudar a conocer con anticipación las posibilidades de éxito de cualquier proyecto TIC, de modo que puedan llevarse a cabo las acciones correctoras apropiadas antes de su ejecución. Específicamente, los objetivos de la investigación son:

- Establecer las posibilidades de éxito de un proyecto, las cuales están determinadas por los valores que tomen las magnitudes: impactos no planificados, desviación de costes (%) y desviación en fecha de entrega (semanas). Estas magnitudes deben tener, tal y como se explicará más adelante al describir la solución técnica, unos valores específicos para considerar que el proyecto al que se refieren puede ser exitoso. La RNA en función de parámetros que caracterizan aspectos de un proyecto como complejidad (8 parámetros), riesgo (1 parámetro), tamaño (5 parámetros) y entorno (2 parámetros) establecerá si un proyecto tiene o no posibilidades de éxito.
- En referencia al modelo de red neuronal, establecer el tamaño del conjunto de entrenamiento, la función de activación más conveniente en las capas ocultas para lograr unos tiempos de entrenamiento y un Mean Square Error (MSE) adecuados. Con una tasa de aprendizaje inferior a 0,1, debe lograrse un tiempo de entrenamiento inferior a 1,50 horas y un MSE más pequeño de 0,00025.

Existen diferentes tipos de Redes Neuronales Artificiales (RNA) [1]: Feed-Forward (FF) [2] [3], Radial Basis Function (RBF) [4][5], Multi-Layer Perceptron (MLP) [6], Convolutional [7], Recurrent Neural Network (RNN), Modular [8], Sequence-To-Sequence Models [9][10][11], las cuales tienen diferentes áreas de aplicación [12] como reconocimiento de imágenes, filtrado de ruido, procesamiento del lenguaje, análisis financiero, evaluación de riesgos, etc. En el ámbito de proyectos las investigaciones existentes han tenido diversos propósitos tales como inclusión de proyectos en los cuadros de mando de la dirección para su monitorización, predicción de costes o rendimiento de contratistas y proveedores. En [13] se construyen varias RNA (Probabilistic Neural Networks (PNN), Multi-Layer-Feed-Forward Networks (MLFFN) para decidir si debe incorporarse un proyecto en los cuadros de mando de los ejecutivos. En otros trabajos se utilizan RNA para predecir los costes de un proyecto. Así, en [14] y [15] se emplea una RNA con Back-Propagation, en [16] una RNA Multi-Layer Perceptron conjuntamente con una Radial Basis Function (RBF). En [17] se usa una RNA con Feed-Forward y en [18] una RNA con MLFF. Algunas investigaciones predicen la duración del proyecto, la adecuación de la metodología de gestión y del contratista al proyecto. Así, [19] calcula la duración de proyectos de desarrollo software utilizando una RNA con MLP, una RBF y un modelo de regresión lineal múltiple (Multiple Linear Regression). [20] Utiliza una MLFFN para predecir la metodología de gestión que se empleará en un proyecto según las características de la organización que lo ejecuta. [21] Construye una RNA que selecciona el contratista más adecuado para la ejecución de un proyecto de construcción.

La novedad de la investigación, descrita en este documento, es que la RNA se aplica a un entorno real de una gran compañía multinacional del sector TIC, concretamente a su proceso de ventas, para mejorar los resultados de sus proyectos. En lo que respecta a la elección de las variables de entrada a la RNA se tienen en cuenta aspectos señalados en varias investigaciones [22], [23], [24], así como los resultados de las técnicas de recopilación de requerimientos que fueron empleadas para acometer la construcción de la solución (revisión de registros históricos, lecciones aprendidas de proyectos anteriores, entrevistas con expertos técnicos, brainstorming y focus groups). Con relación a las investigaciones éstas sugieren que el éxito de un proyecto depende de varias dimensiones, aunque no está claro cuáles de ellas tienen mayor significancia en la determinación del éxito [22]. El denominado enfoque del triángulo de hierro [23] apunta a que alcance, coste y tiempo son los principales asuntos que deben ser gestionados cuidadosamente y de modo conjunto en cualquier proyecto. También el análisis del Standish Group [24] expone que la consideración de un proyecto como exitoso viene establecida por el cumplimiento del plazo de entrega, el acatamiento del presupuesto estimado, la observancia de objetivos, la aportación del valor previsto y la satisfacción. Así, el documento explica que en dichas magnitudes influyen ciertas características del proyecto como el respaldo ejecutivo, la madurez emocional del entorno, la implicación del usuario y los mecanismos de optimización. Además de la experiencia de los recursos, la arquitectura empleada, la agilidad de los procesos, así como la complejidad de la ejecución (tipo, tamaño, tipo de industria, país al que va destinado, tecnología, metodología). También la experiencia previa existente en gestión de proyectos y la claridad de los objetivos del negocio.

Fundamentado en todo lo anterior la solución utiliza 16 variables para predecir si un proyecto será o no exitoso atendiendo a los criterios de la compañía (impactos no planificados, máximo desvío en el presupuesto y plazo de entrega, así como calificación obtenida en la encuesta de cliente). Es posible por tanto durante el proceso de ventas utilizar la solución para variar ciertas características del proyecto (tecnología, arquitectura, número de sedes, etc.), con el fin de obtener diferentes alternativas, que logren cumplir a priori con los criterios de éxito de la compañía. Otro de los aspectos novedosos de la investigación es que utiliza

una RNA con High-Order MLP, algunas funciones de activación (Rectified Linear Unit y Arc-hyperbolic sine) y métodos de inicialización de pesos que no han sido usados, que sepamos, en RNA construidas para obtener conclusiones sobre el éxito de proyectos TIC.

2.- PROBLEMAS PARA ESTIMAR EL ÉXITO DE PROYECTOS

La compañía en la que se ha implementado la solución descrita es una gran compañía multinacional del sector TIC presente en más de ciento ochenta países y diez regiones. La compañía tiene un promedio de doscientos cincuenta clientes por país, realiza proyectos pertenecientes a una gran variedad de áreas, como servicios de despliegue de red, diseño y optimización de redes, consultoría e integración, soporte a clientes, así como sistemas de gestión de negocio. En promedio considerando datos de los últimos 9 años, lleva a cabo alrededor de 72.350 proyectos anuales que son abordados utilizando estándares o metodologías predictivas (pmbok [25] y prince2[26]) y ágiles [27] (scrum, kanban, extreme programming, devops). Todas estas características hacen que sea crítico asegurar al máximo el éxito de cualquier proyecto antes de comenzar su ejecución. La realización de un proyecto forma parte de una de las etapas del proceso de ventas de la compañía, compuesto de varias fases y puntos de decisión. Seguidamente se explica brevemente cada etapa:

Etapas: Crear una oportunidad de venta; se construyen, definen y califican de forma proactiva las oportunidades de venta que deben buscarse; se tienen en cuenta el plan financiero, la cartera de productos, así como los planes de negocio de la compañía. Se efectúa la construcción de casos de negocio preliminares, el registro de oportunidades y la preparación de tácticas de venta.

Al concluir esta etapa se toma la decisión de crear o no la oportunidad de venta. En esta etapa participan los miembros de las cuentas comerciales implicadas.

Etapas: Construcción de la propuesta, se elabora una propuesta para intentar conseguir el contrato. Las actividades aquí incluidas son la determinación del alcance y la preparación de la propuesta. El establecimiento del alcance incluye la detección de los problemas críticos, el análisis y la aclaración de los requisitos, el aseguramiento de los recursos clave, la identificación de entregables, así como la planificación temporal. Se verifica el cumplimiento de las directivas de ventas y de los acuerdos, en caso de que ya existan.

Al finalizar esta etapa se toma la decisión de presentar o no la propuesta fundamentándose en su calidad, su rentabilidad y en las estrategias de la compañía.

En esta etapa se contestan aspectos como si los criterios de paso a esta fase continúan siendo válidos, si la propuesta aborda los requerimientos del cliente respondiendo a la estrategia de negocio, si cumple las estrategias de precios y productos, así como si su nivel de riesgo es aceptable. En esta etapa participan tanto expertos en asuntos técnicos como contractuales y miembros de las cuentas comerciales implicadas.

Etapas: *Negociación de la propuesta*, se pretende conseguir la aceptación de la propuesta por parte del cliente y la contratación. Se realizan las actividades de recopilación de información relativas a la evaluación de la propuesta por parte del cliente, se responde a las aclaraciones solicitadas y finalmente se definen tanto los objetivos como los planes de negociación. En esta etapa toman parte expertos técnicos, especialistas en contratos, además de miembros de las cuentas comerciales.

Al finalizar esta etapa se decide firmar o no el contrato teniendo en cuenta el resultado de la negociación, así como los términos y condiciones establecidos en la compañía.

Etapas: Ejecución del contrato, se asegura que se cumplen las obligaciones contractuales, se lleva a cabo el proyecto en la compañía, se realiza la aceptación, así como el pago por parte del cliente.

Al final de esta etapa se concluye si se ha logrado el cumplimiento de los compromisos de negocio, se verifica si ha habido tanto integridad como puntualidad en las entregas, si éstas contemplan la funcionalidad exigida, si el cliente está satisfecho y si se ha recibido su aceptación. También si se ha suministrado la aceptación a los proveedores, si los pagos han sido realizados, así como si el contrato ha resultado rentable para la compañía.

La solución que se describe en este documento deberá ejecutarse al final de la etapa de negociación de la propuesta; lo cual permitirá saber a priori con buena aproximación si el proyecto podría ser exitoso. En función de ello, se pasará o no a la etapa siguiente del proceso de ventas.

3.- METODOLOGÍA

La metodología empleada incluye:

Determinación de información de entrada que se requiere.

- Información histórica sobre proyectos finalizados, relativa a sus características:
 - Área.
 - Complejidad: nivel de certidumbre/claridad, arquitectura, sedes con interfaces independientes, tecnología, número de interesados, socios/Third-Party Providers (3PP)/Gestión de subcontratas, cambios en los procesos de negocio y necesidad de consultoría especializada.
 - Riesgos.
 - Tamaño: valor del contrato, horas requeridas del jefe de proyecto, tamaño del equipo gestionado, alcance y duración.
 - Entorno: cooperación con el cliente, atractivo.
 - Número de impactos no planificados, desviación respecto presupuesto estimado, variación con relación a la fecha final de disponibilidad y puntuación obtenida en la encuesta de cliente.
- Información del proyecto a analizar (aspectos con mismo significado con los del punto anterior).
 - Área.
 - Complejidad.
 - Riesgos.
 - Tamaño.
 - Entorno.
- Establecimiento de los informes requeridos:
 - Impactos no planificados.
 - Desviación respecto presupuesto estimado.
 - Desviación con relación a la fecha final de disponibilidad.
 - Puntuación conseguida en la encuesta de cliente.
 - Comparativa de escenarios.

Determinación de la red neuronal que se utilizará:

Cada RNA es modelada como una red MLP, donde un vector de entrada (VEp) consta de varios componentes (ijp) que representan diferentes características. Existen N instancias de entrenamiento {VEIp, VEOp} i=1..N, siendo VEIp y VEOp los vectores de entrada y salidas deseadas respectivamente. La RNA ejecuta el siguiente algoritmo [28][29]:

1. Comenzar.
2. Seleccionar una instancia de entrenamiento (VEIp, VEOp).
3. Llevar a cabo la propagación hacia adelante. Para cada instancia de entrenamiento (VEIp, VEOp) se calcula la suma de pesos. La suma de peso $v_j(n)$ para la neurona j en la capa s se define como:

$$v_j^{(s)}(n) = \sum_{i=0}^m w_{ji}^{(s)}(n) y_i^{(s-1)}(n) \quad (1)$$

donde: $y_i^{(s-1)}(n)$ es la salida de la neurona i en la capa s - 1 en la iteración n, $w_{ji}^{(s)}(n)$ representa el peso de la neurona j en la capa s, la cual es alimentada por la neurona i en la capa s-1, y m es la cantidad de neuronas en la capa s - 1.

A diferencia de la investigación ejecutada en [28] [29] la investigación aquí descrita compara para una tasa de aprendizaje determinada el MSE obtenido tras aplicar diferentes funciones de activación en las capas ocultas sobre el conjunto de entrenamiento, determinando finalmente la más adecuada. Las funciones de activación que han sido utilizadas en las capas ocultas son:

- Sigmoid

$$\varphi(x) = \frac{1}{1+e^{-x}} \quad (2)$$

- Rectified Linear Unit

$$\varphi(x) = \max(0, x) \quad (3)$$

- Hyperbolic Tangent

$$\varphi(x) = \frac{2}{1+e^{-x}} = \tanh\left(\frac{x}{2}\right) \quad (4)$$

- Arc-hyperbolic sine

$$\varphi(x) = \ln(x + \sqrt{x^2 + 1}) \quad (5)$$

Como función de activación en las capas de entrada y salida se utilizó la función Sigmoid.

La salida de la neurona j en la capa s es:

$$y_j^{(s)}(n) = \varphi_j(v_j^{(s)}(n)) \quad (6)$$

Si $s = 0$:

$$y_j^0(n) = ve_p^j \quad (7)$$

donde ve_p^j es el j^{th} elemento del vector de entrada VE_p . Si la neurona se ubica en la capa de salida, es decir, $s = S$, el error es:

$$e_j(n) = veo_{pj}(n) - y_j^{(S)}(n) \quad (8)$$

donde $veo_{pj}(n)$ es el elemento j^{th} del vector de respuestas deseadas (VEO_p).

4. *Propagar hacia atrás: Se calculan los gradientes locales (μ):*

- Para la neurona j ubicada en la capa de salida S :

$$\mu_j^{(S)}(n) = e_j^{(S)}(n) \varphi_j'(v_j^{(S)}(n)) \quad (9)$$

- Para la neurona j ubicada en la capa oculta s :

$$\mu_j^{(s)}(n) = \varphi_j'(v_j^{(s)}(n)) \sum_k \mu_k^{(s+1)}(n) w_{kl}^{(s+1)}(n) \quad (10)$$

Significando, φ' diferenciación.

El ajuste de pesos de la red se efectúa según la regla de delta generalizada [29]:

$$w_{ji}^{(s)}(n+1) = w_{ji}^{(s)}(n) - \tau \mu_j^{(s)}(n) y_i^{(s-1)}(n) \quad (11)$$

donde τ es la tasa de aprendizaje.

5. *Volver al punto 2 hasta lograr el valor determinado para el MSE.*

A lo largo del entrenamiento esta acción se lleva a cabo varias veces, ajustando continuamente los pesos.

Los métodos utilizados para la inicialización de pesos fueron los más adecuados según investigaciones recientes, a la función de activación empleada, para la función Sigmoid, Hyperbolic Tangent, y Arc-hyperbolic sine function se empleó el método de Glorot y Bengio [31] y para la Rectified Linear Unit el método de He., Zhang, Ren, y, Sun [32].

Antes de ser procesados por la RNA los datos fueron normalizados por el método Min-Max.

Establecimiento de la metodología a seguir:

Para la gestión del proyecto se decidió emplear un método predictivo debido a que se conocía claramente el fin que se deseaba alcanzar, los requisitos gozaban de gran estabilidad, las modificaciones eran infrecuentes y el equipo había implementado varias veces soluciones basadas en RNA. Debido a que el director del proyecto tenía amplia experiencia en gestión con el estándar pmbok[25], se decidió utilizar este método en lugar de Prince2.

El proyecto estuvo compuesto de 5 etapas: Iniciación, Planificación, Ejecución y Cierre.

En la fase de Iniciación se establecieron tanto el alcance como los recursos financieros; se identificaron los interesados, determinando la influencia que éstos podrían tener sobre los resultados del proyecto y se asignó el jefe de proyecto. El entregable único en esta fase fue el acta de constitución del proyecto.

En la fase de planificación se detalló el alcance, se definieron los objetivos, se establecieron las acciones requeridas para conseguirlos y se determinó el plan de gestión de proyecto (plan de calidad, plan de recursos humanos, plan de comunicación, plan

de gestión de riesgos, plan de aprovisionamiento). Se precisaron las actividades, se estableció su secuencia, se determinaron los recursos necesarios, así como la duración para cada actividad. También se especificó el calendario del proyecto, se estimaron los costes, se calculó el presupuesto e identificaron los riesgos además se realizó tanto el análisis cualitativo como el cuantitativo de riesgos. Los entregables en esta fase fueron la especificación y el plan de gestión de proyecto.

En la etapa de ejecución se completó el trabajo establecido en el plan de gestión de proyecto. La ejecución del proyecto fue dirigida y gestionada. Además, se aseguró la calidad del proyecto, se distribuyó la información, se gestionaron las expectativas de los interesados, los aprovisionamientos y la contratación de proveedores.

En la etapa de cierre, se finalizaron todas las actividades para completar el proyecto, se obtuvo su aceptación, se documentaron las lecciones aprendidas, se archivaron los documentos relevantes. También se efectuó el cierre de los contratos con proveedores y de aprovisionamiento.

En todas las etapas se llevaron a cabo actividades relativas a la monitorización y control del proyecto.

4.- LA SOLUCIÓN TÉCNICA

Un prototipo de la herramienta Project Successful Prediction Tool TPPS fue desarrollado y desplegado. La herramienta consta de varios componentes, los cuales se muestran en la Figura 1, una base de datos ORACLE [33] (12c Release 2), una GUI Java y 1 SA. Se emplean los productos Python (versión 3.7.0) [34], Oracle Application Server 10g (version 10.1.3.3) y MQSeries Messaging (version 9.1) [35].




Fig. 1. Architecture of the TPPS

4.1.- APEP (AGENTE DE PREVISIÓN DE ÉXITO DE PROYECTO)

Este agente calcula si un proyecto TIC puede ser no exitoso, según los criterios determinados en la compañía, que son:

Ex₁. Se refiere a los impactos no planificados en un proyecto y debe ser 0.

Ex₂. Máxima desviación del presupuesto estimado: -4%. Es decir, la desviación respecto al presupuesto debe situarse en el rango [0, -4]% del mismo.

Ex₃. Máxima desviación de la fecha final de disponibilidad del proyecto: 2 semanas. Es decir, la desviación permitida respecto a la fecha prevista de terminación debe encontrarse en el rango [0, +2 semanas].

Ex₄. Valoración del proyecto por parte del cliente, la cual debe ser superior a 7. Es decir, teniendo en cuenta que 10 es la máxima calificación posible, la evaluación debe encontrarse en el rango [7, 10].

Un proyecto TIC puede describirse a través de características como complejidad, riesgo, tamaño y entorno; siendo cada una de ellas evaluada, a través de 16 aspectos, los cuales, son detallados a continuación:

Complejidad, incluye:

- Nivel de certidumbre/claridad (C₁):
 - Sin incertidumbre, 100% claro.
 - Objetivos, métodos, productos y procesos claros.
 - Objetivos y productos claros; métodos y procesos poco claros.
 - Objetivos y productos poco claros; métodos y procesos claros.
 - Objetivos y productos, métodos y procesos poco claros.
- Complejidad arquitectónica (C₂):
 - Plug & play.
 - Adaptación/reutilización de un producto ya establecido.
 - Integración de varios de los productos ya existentes dentro de un área.
 - Integración de varios productos ya existentes de diferentes áreas.
 - Integración de varios productos unos ya existentes y otros nuevos de la misma o de diferentes áreas.
- Número de sedes con interfaces de cliente independientes. Sedes diferentes implican diferencias geográficas u organizativas (distintas entidades jurídicas u organizaciones regionales), lo que puede suponer que cada una tenga diferentes sistemas y tipos de organización (C₃):
 - 1 sede en el mismo país.
 - 2 sedes en el mismo país.
 - 3 sedes en el mismo país.
 - >3 sedes en el mismo país.
 - Sedes en más de 1 país, estado o región.
- Tecnología (C₄):
 - Madura, bien probada.
 - Versión en entorno operativo, bien conocida.
 - Versión en entorno de pre-operación, generalmente bien conocida.
 - En piloto, First Office Application (FOA), con adaptación menor.
 - En piloto, First Office Application (FOA), con adaptación media o grande.
- Número de interesados (C₅): <2, 2, 3, 4, >4
- Socios/ Third-Party Providers (3PP)/Gestión de subcontratas (C₆): Ninguna, 1, 2, 3, > 3
- Cambios en los procesos de negocio por la introducción de los productos/sistemas (C₇):
 - Ninguno.
 - No se esperan, pero conviene hacer un seguimiento.
 - Se requieren cambios sólo en algunos procesos no críticos.
 - Se requieren cambios sólo en algunos procesos críticos.
 - Se requieren cambios en todos los procesos.
- Implicación de consultoría muy especializada (C₈):
 - Ninguna
 - Baja. Reutiliza una parte importante de la solución anterior, adaptación media.
 - Media. Alto nivel de rediseño de la solución anterior, se requiere una participación mayor de expertos y de diálogo cliente.
 - Alta. Se requiere análisis de los procesos de negocio y consultoría de la arquitectura de negocio. Es precisa la participación de la dirección por parte del cliente.
 - Muy Alta. Se requiere análisis de complejos procesos de negocio y consultoría de una compleja arquitectura de negocio. Es precisa la participación de la dirección por parte del cliente.

Riesgos (técnicos, financieros, planificación, suministros o de recursos) (R_1):

- Mínimo / ninguno.
- Bajo.
- Medio.
- Riesgo alto para un área de cliente, pero no para la totalidad de la compañía.
- Riesgo alto para la totalidad de la compañía.

Tamaño:

- Valor del contrato (T_1):

- < 50.000 €.

- ≥ 50.000 € y < 1.00.000 €.

- ≥ 100.000 € y < 1.000.000 €.

- > 1.000.000 € y < 10.000.000 €.

- $\geq 10.000.000$ €.

- Horas requeridas del jefe de proyecto (T_2): <160, ≥ 160 y < 300, ≥ 300 y < 1000, ≥ 1000 y < 2000, ≥ 2000 .
- Tamaño del equipo gestionado, número de personas (T_3): <5, ≥ 5 y <10, ≥ 10 y <50, ≥ 50 y <200, ≥ 200 .
- Alcance del proyecto (T_4): Muy pequeño, Pequeño, Medio, Grande, Muy Grande.
- Duración del proyecto (T_5): < 2 meses, ≥ 2 meses y < 4 meses, ≥ 4 meses < 6 meses, ≥ 6 meses < 12 meses, ≥ 12 meses.

Entorno:

- Fácil cooperación con el cliente (E_1):
 - Buena relación ya consolidada de otros proyectos previos.
 - Buena cooperación en toda la organización con la que el proyecto interactúa.
 - Buena cooperación pero no con algunas partes no clave de la organización.
 - Una parte clave de la organización con la que el proyecto interactúa bloquea o impide el progreso.
 - Toda la organización con la que el proyecto interactúa bloquea el proyecto.
- Atractivo (idioma, cultura, dificultades) (E_2):
 - Ubicación local.
 - Otro país, entorno atractivo.
 - Otro país, entorno poco atractivo. Dificil contratar personal.

Por lo que respecta a la construcción de la RNA, aunque inicialmente se barajó la posibilidad de calcular un vector de salida con cuatro componentes, finalmente, se optó por calcular por separado cada una de las variables Ex_1 , Ex_2 , Ex_3 y Ex_4 . Esto fue debido a que existían departamentos con otros casos de uso en otros proyectos que únicamente empleaban alguna de las variables de salida. Por ejemplo, el área de calidad sólo estaba interesada en Ex_4 , el departamento de control financiero únicamente en Ex_2 y el departamento de gestión de riesgos sólo en Ex_1 . La construcción de la RNA, en estos casos, estuvo incluida como actividad (con sus costes y sus plazos) en otros proyectos de la compañía destinados a dichas áreas, beneficiándose de esta sinergia el proyecto aquí descrito. Adicionalmente, debe notarse que la utilización de un vector de salida hubiese implicado, probablemente, aumentar la cantidad de capas ocultas y el número de nodos para cumplir con los objetivos establecidos respecto a tasa de aprendizaje, tiempo de entrenamiento y MSE.

El agente APEP emplea JDBC para interactuar con la base de datos (DB) y MqSeries para dialogar el repositorio de conocimiento corporativo. Los datos históricos relativos a C_1 , C_2 , C_3 , C_4 , C_5 , C_6 , C_7 , C_8 , R_1 , T_1 , T_2 , T_3 , T_4 , T_5 , E_1 , E_2 y Ex_1 , Ex_2 , Ex_3 o Ex_4 , son las variables de entrada que cada RNA utilizará para predecir los valores Ex_1 , Ex_2 , Ex_3 o Ex_4 para el proyecto a analizar que después serán cargados en la base de datos.

Los datos históricos C1, C2, C3, C4, C5, C6, C7, C8, R1, T1, T2, T3, T4, T5, E1, E2 además de Ex1, Ex2, Ex3 o Ex4, según el caso, relativos a un proyecto definen las coordenadas ijp de un vector de entrenamiento VEp. Esta información es extraída del repositorio corporativo y cargada en la base de datos.

Las 4 RNA constan de 5 capas de nodos: la capa de entrada, 3 capas ocultas y la capa de salida. La capa de entrada tiene 16 nodos y las capas ocultas tienen 11 nodos, mientras que la capa de salida posee un sólo nodo. Se emplearon 651.150 vectores de entrada que corresponden a observaciones de proyectos recolectadas durante 9 años. Los últimos 260.460 vectores de entrada se usaron para la prueba de cada RNA y los restantes 390.690 vectores de entrada constituyeron el conjunto de entrenamiento. Después de 651.150 iteraciones y con la función de activación Rectified Linear Unit en las capas ocultas, en el caso de Ex1, el MSE para el conjunto de entrenamiento y para la prueba fue 0,00019 y 0,00017. En el caso de Ex2 estas magnitudes tuvieron los valores 0,00024 y 0,00021. En lo que respecta a Ex3, estos valores fueron 0,00015 y 0,00014. Para Ex4 estos valores fueron 0,00023 y 0,00020. El entrenamiento se terminó después de 651.150 iteraciones ya que en posteriores iteraciones no hubo una disminución relevante en ninguno de los MSE. La tasa de aprendizaje, parámetro τ en la ecuación (11), fue para Ex1 0,09652, para Ex2 0,09543, para Ex3 0,09720 y para Ex4 0,09512.

Cada RNA se componen de un total de 50 nodos y 21.296 conexiones, a modo de muestra la Tabla 1 explicita, para la RNA con nodo de salida Ex2, los pesos finales de las conexiones de los 11 nodos de la capa oculta 3 con el nodo de la capa de salida.

ω_{ij}^s peso de la conexión de la neurona j en la capa s , la cual es alimentada por la neurona i en la capa $s-1$

$\omega_{11}^5 = -0,04818$	$\omega_{51}^5 = 0,05416$	$\omega_{91}^5 = 0,17728$
$\omega_{21}^5 = 0,03484$	$\omega_{61}^5 = -0,09697$	$\omega_{101}^5 = -0,21514$
$\omega_{31}^5 = -0,08958$	$\omega_{71}^5 = 0,16748$	$\omega_{111}^5 = -0,28474$
$\omega_{41}^5 = 0,49249$	$\omega_{81}^5 = 0,09529$	

Tabla 1. Para la RNA con nodo de salida Ex2, pesos finales de las conexiones de los 11 nodos de la capa oculta 3 con el nodo de la capa de salida, utilizando la función Rectified Linear Unit como función de activación en las capas ocultas, con un tamaño del conjunto de entrenamiento de 390.690, con MSE 0,00024, para $\tau = 0,09543$.

4.2.- IU (INTERFAZ DE USUARIO)

Este componente se encarga de la mediación entre los usuarios y el sistema. Es una interfaz escrita en JAVA, posee botones, cuadros de texto y menús con ayuda. Permite una visión de usuario adaptada a cada perfil, conforme a sus necesidades y nivel de responsabilidad (responsables de área comercial, especialistas contractuales y expertos técnicos, locales, regionales y globales).

La IU se ha diseñado separando las funciones propias de servidor y cliente. Para las primeras, la herramienta dispone de un servidor de aplicaciones ORACLE que facilita la escalabilidad y hace posible llevar a cabo operaciones de petición/respuesta e informar de los eventos que ocurren. El cliente que se ejecuta en el PC del usuario final es un applet Java autocargable. De modo que cualquier modificación del ejecutable se refresca sin requerir la intervención del usuario.

El personal de las cuentas comerciales de cada área y país introduce los datos C1, C2, C3, C4, C5, C6, C7, C8, R1, T1, T2, T3, T4, T5, E1, E2 del proyecto a analizar antes de finalizar la etapa de negociación de la propuesta. Esta información habrá sido elaborada y consensuada entre los expertos técnicos, especialistas en asuntos contractuales y responsables de las áreas comerciales.

Es posible modificar los parámetros que se hubiesen introducido inicialmente a fin de que puedan abordarse otros escenarios en el proyecto que cumplan con lo establecido en la compañía para: Ex1, Ex2, Ex3 y Ex4. Desde la IU pueden visualizarse los resultados obtenidos en cada escenario con un detalle de sus valores, tal como muestra la Figura 2.

Si para algún escenario el resultado obtenido es adecuado, se continuará la negociación de la propuesta a fin de que sea aceptada por el cliente. Sólo si la propuesta es aceptada y todos los demás aspectos analizados en la etapa de negociación son correctos, se firmará el contrato y se proseguirá con la etapa de ejecución.

Desde la IU es posible modificar los parámetros máximos para Ex_1 , Ex_2 y Ex_3 , dado que de un año a otro pueden haberse cambiado las directivas establecidas en la compañía. Las máximas modificaciones permitidas en dichos máximos, acordadas con la dirección y que permiten cumplir los objetivos (tasa de aprendizaje inferior a 0,1, tiempo de entrenamiento menor a 1,50 horas y MSE más pequeño de 0,00025), son:

- Ex_1 . El valor máximo puede ser cambiado a +1.
- Ex_2 . El valor máximo puede ser modificado en el rango [-4, -4,25].
- Ex_3 . El valor máximo puede ser modificado en el rango [2, 2,25].
- Ex_4 : El valor máximo no puede ser cambiado, pues 10 es la máxima calificación posible.

5.- RESULTADOS Y DISCUSIÓN

El prototipo fue instalado en una máquina con : 4 CPU, 500 GB hard disk, 4 GB memory. La herramienta ha sido usada durante un año, demostrándose que la investigación había alcanzado los objetivos de investigación propuestos:

- En relación a determinar las posibilidades de éxito de un proyecto.

Se construyeron 4 RNA que partiendo de C_1 , C_2 , C_3 , C_4 , C_5 , C_6 , C_7 , C_8 , R_1 , T_1 , T_2 , T_3 , T_4 , T_5 , E_1 , E_2 de un proyecto TIC son capaces de establecer los parámetros Ex_1 , Ex_2 , Ex_3 y Ex_4 que determinan su éxito.

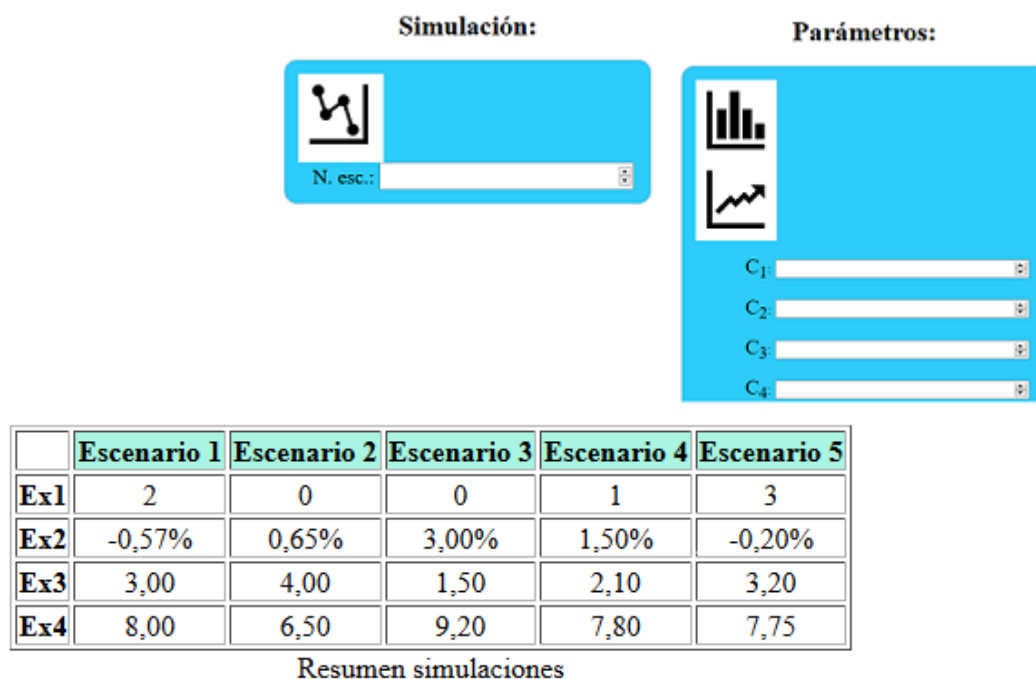


Fig. 2. Arriba Izquierda Formulario de la IU utilizado para solicitar al usuario el número de simulaciones a realizar. Arriba Derecha. Formulario de la IU para pedir al usuario la entrada de datos de un Escenario. Abajo, resultado mostrado tras ejecutar 5 simulaciones para un proyecto.

- Con respecto a cada RNA:

La determinación de la estructura más adecuada de la red se llevó a cabo analizando diferentes configuraciones caracterizadas por un número distinto de capas ocultas y nodos: 1 capa oculta con 11 nodos, 2 y 3 capas ocultas con 2, 5 y 11 nodos. Las configuraciones fueron estudiadas para las funciones de activación Sigmoid, Rectified Linear Unit, Hyperbolic Tangent y Arc-hyperbolic sine en las capas ocultas. Tanto para la capa de entrada como para la de salida se empleó la función Sigmoid. En cada configuración se realizaron 145 experimentos con distintos tiempos y tamaños del conjunto de entrenamiento y se calculó el MSE

promedio. La Figura 3 muestra, a modo de ejemplo, para la RNA con variable de salida Ex2, los resultados obtenidos para un tamaño del conjunto de entrenamiento igual a 48.836, un tiempo de entrenamiento igual a 0,75 horas y una tasa de aprendizaje $\tau = 0,09543$. Los valores MSE más pequeños se lograron para la configuración de 3 capas ocultas con 11 nodos, donde el MSE fue 0,03184, 0,00030, 0,00035 y 0,07138 para las funciones Sigmoid, Rectified Linear Unit, Hyperbolic Tangent y Arc-hyperbolic sine. Con cada una de las configuraciones analizadas, una vez verificada la fase de entrenamiento, se llevó a cabo la fase de prueba. La Figura 4 muestra, a modo de ejemplo, para la RNA con variable de salida Ex2, los resultados obtenidos para un tamaño del conjunto de prueba igual a 602.314, un tiempo de entrenamiento igual a 0,75 horas y una tasa de aprendizaje $\tau = 0,09543$. Nuevamente, los valores MSE más pequeños se lograron para la configuración de 3 capas ocultas con 11 nodos, donde el MSE fue 0,03179, 0,00029, 0,00034 y 0,05564 para las funciones Sigmoid, Rectified Linear Unit, Hyperbolic Tangent y Arc-hyperbolic sine.

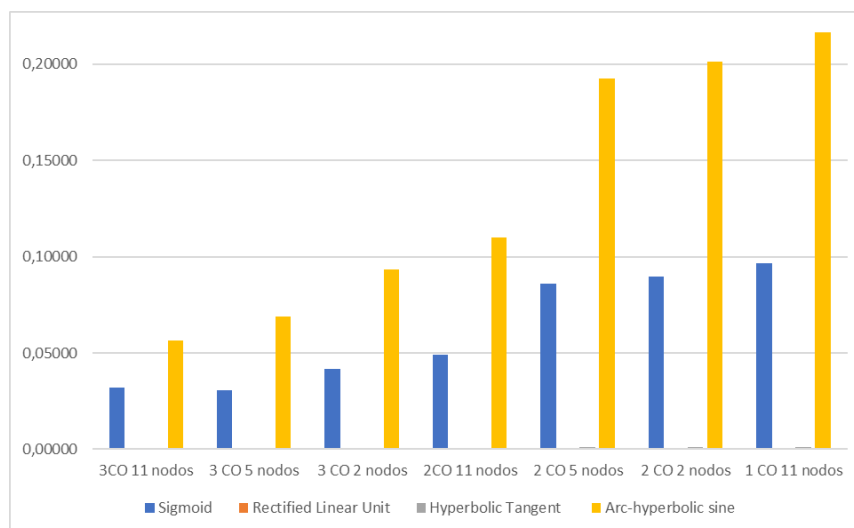
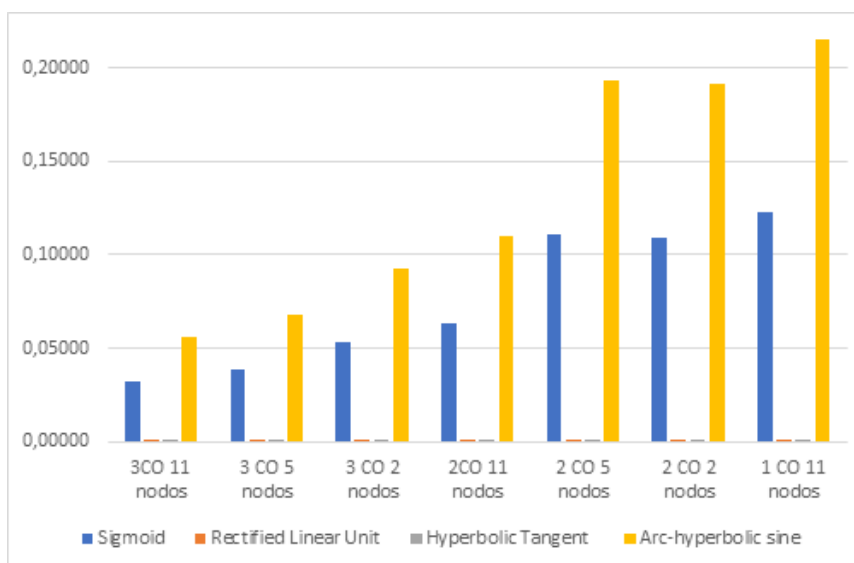


Fig. 3. Resultado de comparar varias configuraciones de la RNA: 1 capa oculta con 11 nodos, 2 y 3 capas ocultas con 2, 5 y 11 nodos, utilizando las funciones de activación: Sigmoid, Rectified Linear Unit, Hyperbolic Tangent y Arc-hyperbolic sine en las capas ocultas para un tamaño del conjunto de entrenamiento de 48.836, un tiempo de entrenamiento igual a 0,75 horas y una tasa de aprendizaje $\tau = 0,09543$.




	APLICACIÓN DE REDES NEURONALES ARTIFICIALES A LA PREDICCIÓN DEL ÉXITO DE PROYECTOS TIC	TECNOLOGÍA DE LAS TELECOMUNICACIONES
ARTICULO DE INVESTIGACIÓN	Mary Luz Mouronte-López	PROGRAMAS INFORMÁTICOS (SOFTWARE) INTELIGENCIA ARTIFICIAL

Fig. 4. Para la RNA con nodo de salida Ex2 y la fase de prueba, resultado de comparar varias configuraciones de la RNA: 1 capa oculta con 11 nodos, 2 y 3 capas ocultas con 2, 5 y 11 nodos, utilizando las funciones de activación: Sigmoid, Rectified Linear Unit, Hyperbolic Tangent y Arc-hyperbolic sine en las capas ocultas para un tamaño del conjunto de entrenamiento de 48.836, un tiempo de entrenamiento igual a 0,75 horas y una tasa de aprendizaje $\tau = 0,09543$.

Con la estructura que parecía ser más adecuada para la RNA se efectuaron nuevamente 145 experimentos, con distintos tamaños del conjunto de entrenamiento y funciones de activación con el objetivo de lograr un tiempo de entrenamiento promedio inferior a 1,50 horas y un MSE promedio inferior a 0,00025.

Se hace notar que podrían haberse efectuado pruebas con un número mayor de configuraciones, sin embargo, al haberse conseguido con una de las siete realizadas (3 capas ocultas con 11 nodos) los objetivos fijados por la dirección de la compañía ésta lo consideró suficiente.

Las Tablas 2, 3, 4 y 5 muestran los resultados para Ex1. Para una tasa de aprendizaje τ igual a 0,09652 y una función de activación Sigmoid en las capas ocultas la Tabla 2 muestra el MSE para diversos tamaños del conjunto de entrenamiento (Input Vector) y diferentes valores del tiempo de entrenamiento promedio (average training time (att)). Las Tablas 3, 4 y 5 muestran la misma información, pero empleando como función de activación las funciones Rectified Linear Unit, Hyperbolic Tangent y Arc-hyperbolic sine en las capas ocultas, respectivamente. Para cada att se señala también su desviación estándar (σ).

att ($\pm\sigma$)	0,75h($\pm 0,00006$)	1,10 h ($\pm 0,00005$)	1,20 h ($\pm 0,00005$)	1,43 h ($\pm 0,00006$)
Input vectors				
48.836	0,04314	0,04132	0,04051	0,03951
97.673	0,04017	0,03728	0,03507	0,03546
195.345	0,02168	0,01996	0,01910	0,01846
390.690	0,01998	0,01854	0,01681	0,01671

Tabla 2. Para Ex1, utilizando la función Sigmoid como función de activación en las capas ocultas, MSE para $\tau = 0,09652$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h: horas)

att ($\pm\sigma$)	0,75 h ($\pm 0,00007$)	1,10 h ($\pm 0,00004$)	1,20 h ($\pm 0,00006$)	1,43 h ($\pm 0,00007$)
Input vectors				
48.836	0,00350	0,00338	0,00327	0,00327
97.673	0,00029	0,00026	0,00025	0,00025
195.345	0,00027	0,00024	0,00023	0,00022
390.690	0,00025	0,00021	0,00020	0,00019

Tabla 3. Para Ex1, utilizando la función Rectified Linear Unit como función de activación en las capas ocultas, MSE para $\tau = 0,09652$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h: horas)

att ($\pm\sigma$)	0,75 h ($\pm 0,00007$)	1,10 h ($\pm 0,00006$)	1,20 h ($\pm 0,00008$)	1,43 h ($\pm 0,00009$)
Input vectors				
48.836	0,00037	0,00036	0,00035	0,00034
97.673	0,00036	0,00033	0,00031	0,00031
195.345	0,00036	0,00034	0,00032	0,00031
390.690	0,00036	0,00034	0,00031	0,00031

Tabla 4. Para Ex₁, utilizando Hyperbolic Tangent como función de activación en las capas ocultas, MSE para $\tau = 0.09652$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h: horas)

att ($\pm\sigma$)	0,75 h ($\pm 0,00008$)	1,10 h ($\pm 0,00007$)	1,20 h ($\pm 0,00006$)	1,43 h ($\pm 0,00007$)
Input vectors				
48.836	0,07038	0,06743	0,06610	0,06447
97.673	0,06850	0,06357	0,05981	0,06045
195.345	0,06530	0,06013	0,05754	0,05560
390.690	0,05914	0,05488	0,04974	0,04945

Tabla 5. Para Ex₁, utilizando Arc-hyperbolic sine como función de activación en las capas ocultas, MSE para $\tau = 0,09652$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h: horas)

Como se puede ver, en el caso de la RNA con nodo de salida Ex₁, el mejor resultado que cumple con los objetivos de la investigación se consigue con un tamaño del conjunto de entrenamiento de 390.690 y una función de activación Rectified Linear Unit en las capas ocultas. En este caso, se logra un tiempo de entrenamiento promedio de 1.43 horas, un MSE medio de 0,00019 y de 0,00018 para el conjunto de entrenamiento y el conjunto de prueba.

Los resultados para Ex₂ se muestran en las Tablas 6, 7, 8 y 9. Para una tasa de aprendizaje τ igual a 0,09543 y una función de activación Sigmoid en las capas ocultas la Tabla 6 presenta el MSE para diversos tamaños del conjunto de entrenamiento (Input Vector) y diferentes tiempos de entrenamiento promedio (average training time (att)). Las Tablas 7, 8 y 9 muestran la misma información, pero utilizando como función de activación las funciones Rectified Linear Unit, Hyperbolic Tangent y Arc-hyperbolic sine en las capas ocultas, respectivamente. Para cada att se indica también su desviación estándar (σ).

att ($\pm\sigma$)	0,75h ($\pm 0,00007$)	1,10 h ($\pm 0,00008$)	1,20 h ($\pm 0,00007$)	1,43 h ($\pm 0,00008$)
Input vectors				
48.836	0,03184	0,03050	0,02990	0,02916
97.673	0,03110	0,02886	0,02715	0,02745
195.345	0,03006	0,02767	0,02648	0,02559
390.690	0,02998	0,02782	0,02522	0,02507

Tabla 6. Para Ex₂, utilizando la función Sigmoid como función de activación en las capas ocultas, MSE para $\tau = 0,09543$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h: horas)

att ($\pm\sigma$)	0,75 h ($\pm 0,00008$)	1,10 h ($\pm 0,00009$)	1,20 h ($\pm 0,00006$)	1,43 h ($\pm 0,00005$)
Input vectors				
48.836	0,00030	0,00029	0,00028	0,00028
97.673	0,00030	0,00027	0,00026	0,00026
195.345	0,00029	0,00026	0,00025	0,00024
390.690	0,00028	0,00026	0,00024	0,00024

Tabla 7. Para Ex2, utilizando la función Rectified Linear Unit como función de activación en las capas ocultas, MSE para $\tau = 0,09543$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h: horas)

att ($\pm\sigma$)	0,75 h ($\pm 0,00009$)	1,10 h ($\pm 0,00009$)	1,20 h ($\pm 0,00010$)	1,43 h ($\pm 0,00008$)
Input vectors				
48.836	0,00035	0,00034	0,00033	0,00032
97.673	0,00035	0,00032	0,00030	0,00030
195.345	0,00033	0,00031	0,00029	0,00028
390.690	0,00033	0,00031	0,00028	0,00028


Tabla 8. Para Ex2, utilizando Hyperbolic Tangent como función de activación en las capas ocultas, MSE para $\tau = 0,09543$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h: horas)

att ($\pm\sigma$)	0,75 h ($\pm 0,00009$)	1,10 h ($\pm 0,00009$)	1,20 h ($\pm 0,00010$)	1,43 h ($\pm 0,00008$)
Input vectors				
48.836	0,07138	0,06839	0,06704	0,06539
97.673	0,06973	0,06471	0,06088	0,06154
195.345	0,06739	0,06205	0,05938	0,05738
390.690	0,06722	0,06238	0,05654	0,05621

Tabla 9. Para Ex2, utilizando Arc-hyperbolic sine como función de activación en las capas ocultas, MSE para $\tau = 0,09543$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h: horas)

Como se puede observar, en el caso de la RNA con nodo de salida Ex₂, el resultado que cumple con los objetivos de la investigación es un tamaño del conjunto de entrenamiento de 390.690 y una función de activación Rectified Linear Unit en las capas ocultas, para la que se obtiene un tiempo de entrenamiento promedio de 1.20 horas, un MSE promedio de 0,00024 y de 0,00021, para el conjunto de entrenamiento y el conjunto de prueba respectivamente.

Las Tablas 10, 11, 12 y 13 presentan los resultados para Ex₃. Para una tasa de aprendizaje τ igual a 0,09720 y una función de activación Sigmoid en las capas ocultas la Tabla 10 muestra el MSE para diversos tamaños del conjunto de entrenamiento (Input Vector) y diferentes valores del tiempo de entrenamiento promedio (average training time (att)). Las Tablas 11, 12 y 13 muestran

	APLICACIÓN DE REDES NEURONALES ARTIFICIALES A LA PREDICCIÓN DEL ÉXITO DE PROYECTOS TIC	TECNOLOGÍA DE LAS TELECOMUNICACIONES
ARTICULO DE INVESTIGACIÓN	Mary Luz Mouronte-López	PROGRAMAS INFORMÁTICOS (SOFTWARE) INTELIGENCIA ARTIFICIAL

idéntica información, pero empleando como función de activación las funciones Rectified Linear Unit , Hyperbolic Tangent y Arc-hyperbolic sine en las capas ocultas, respectivamente. Para cada att se presenta también su desviación estándar (σ).

att ($\pm\sigma$)	0,75h($\pm 0,00007$)	1,10 h ($\pm 0,00008$)	1,20 h ($\pm 0,00006$)	1,43 h ($\pm 0,00008$)
Input vectors				
48.836	0,03415	0,03271	0,03207	0,03128
97.673	0,03215	0,02983	0,02807	0,02838
195.345	0,03107	0,02860	0,02737	0,02645
390.690	0,02094	0,01943	0,01762	0,01751

Tabla 10. Para Ex3, utilizando la función Sigmoid como función de activación en las capas ocultas, MSE para $\tau = 0,09720$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h:horas)

att ($\pm\sigma$)	0,75 h($\pm 0,00008$)	1,10 h ($\pm 0,00009$)	1,20 h ($\pm 0,00007$)	1,43 h ($\pm 0,00005$)
Input vectors				
48.836	0,00025	0,00024	0,00023	0,00023
97.673	0,00023	0,00021	0,00020	0,00020
195.345	0,00020	0,00018	0,00017	0,00017
390.690	0,00019	0,00018	0,00016	0,00015

Tabla 11. Para Ex3, utilizando la función Rectified Linear Unit como función de activación en las capas ocultas, MSE para $\tau = 0,09720$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h:horas)

att ($\pm\sigma$)	0,75 h($\pm 0,00009$)	1,10 h ($\pm 0,00007$)	1,20 h ($\pm 0,00008$)	1,43 h ($\pm 0,00004$)
Input vectors				
48.836	0,00032	0,00031	0,00030	0,00029
97.673	0,00032	0,00029	0,00027	0,00027
195.345	0,00031	0,00029	0,00027	0,00026
390.690	0,00030	0,00028	0,00025	0,00025

Tabla 12. Para Ex3, utilizando Hyperbolic Tangent como función de activación en las capas ocultas, MSE para $\tau = 0,09720$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h:horas)

att ($\pm\sigma$)	0,75 h ($\pm 0,00009$)	1,10 h ($\pm 0,00009$)	1,20 h ($\pm 0,00010$)	1,43 h ($\pm 0,00008$)
Input vectors				
48.836	0,05341	0,05117	0,05016	0,04893
97.673	0,05230	0,04853	0,04566	0,04616
195.345	0,05115	0,04710	0,04507	0,04355
390.690	0,05012	0,04651	0,04216	0,04191

Tabla 13. Para Ex3, utilizando Arc-hyperbolic sine como función de activación en las capas ocultas, MSE para $\tau = 0,09720$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h:horas)

Como se puede ver, en el caso de la RNA con nodo de salida Ex3, el resultado que verifica mejor los objetivos de la investigación se logra con un tamaño del conjunto de entrenamiento de 390.690 y una función de activación Rectified Linear Unit en las capas ocultas. Se obtiene un tiempo de entrenamiento medio de 1.43 horas, un MSE promedio de 0,00015 y de 0,00014 para el conjunto de entrenamiento y el conjunto de prueba, respectivamente.

Los resultados para Ex4 se muestran en las Tablas 14, 15, 16 y 17. Para una tasa de aprendizaje τ igual a 0,09512 y una función de activación Sigmoid en las capas ocultas la Tabla 14 muestra el MSE para varios tamaños del conjunto de entrenamiento (Input Vector) y distintos valores del tiempo de entrenamiento promedio (average training time (att)). Las Tablas 15, 16 y 17 muestran la misma información pero usando como función de activación las funciones Rectified Linear Unit, Hyperbolic Tangent y Arc-hyperbolic sine en las capas ocultas, respectivamente. Para cada att se señala también su desviación estándar (σ).

att ($\pm\sigma$)	0,75h ($\pm 0,00007$)	1,10 h ($\pm 0,00008$)	1,20 h ($\pm 0,00007$)	1,43 h ($\pm 0,00005$)
Input vectors				
48.836	0,03003	0,02877	0,02820	0,02750
97.673	0,02950	0,02738	0,02575	0,02604
195.345	0,02856	0,02629	0,02516	0,02431
390.690	0,02870	0,02663	0,02414	0,02400

Tabla 14. Para Ex4, utilizando la función Sigmoid como función de activación en las capas ocultas, MSE para $\tau = 0,09512$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h:horas)

att ($\pm\sigma$)	0,75 h ($\pm 0,00008$)	1,10 h ($\pm 0,00008$)	1,20 h ($\pm 0,00006$)	1,43 h ($\pm 0,00005$)
Input vectors				
48.836	0,00030	0,00029	0,00028	0,00028
97.673	0,00030	0,00027	0,00026	0,00026
195.345	0,00029	0,00026	0,00025	0,00024
390.690	0,00028	0,00026	0,00024	0,00023

Tabla 15. Para Ex4, utilizando la función Rectified Linear Unit como función de activación en las capas ocultas, MSE para $\tau = 0,09512$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h:horas)

att ($\pm\sigma$)	0,75 h ($\pm 0,00009$)	1,10 h ($\pm 0,00009$)	1,20 h ($\pm 0,00010$)	1,43 h ($\pm 0,00008$)
Input vectors				
48.836	0,00042	0,00041	0,00040	0,00038
97.673	0,00041	0,00037	0,00035	0,00035
195.345	0,00039	0,00037	0,00034	0,00033
390.690	0,00039	0,00037	0,00033	0,00033

Tabla 16. Para Ex_4 , utilizando Hyperbolic Tangent como función de activación en las capas ocultas, MSE para $\tau = 0,09512$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h: horas)

att ($\pm\sigma$)	0,75 h ($\pm 0,00005$)	1,10 h ($\pm 0,00009$)	1,20 h ($\pm 0,00007$)	1,43 h ($\pm 0,00006$)
Input vectors				
48.836	0,07138	0,06839	0,06704	0,06539
97.673	0,06973	0,06471	0,06088	0,06154
195.345	0,06739	0,06205	0,05938	0,05738
390.690	0,06722	0,06238	0,05654	0,05621

Tabla 17. Para Ex_4 , utilizando Arc-hyperbolic sine como función de activación en las capas ocultas, MSE para $\tau = 0,09512$, varios tamaños del conjunto de entrenamiento y tiempo de entrenamiento promedio. (att: average training time, σ : desviación estándar, h: horas)

Como se puede ver, para la RNA con nodo de salida Ex_4 , el resultado que cumple mejor con los objetivos de la investigación es un conjunto de entrenamiento con tamaño 390.690 y una función de activación Rectified Linear Unit en las capas ocultas. Se obtiene un tiempo de entrenamiento medio de 1.43 horas, un MSE promedio igual a 0,00023 y 0,00021 para el conjunto de entrenamiento y el conjunto de prueba, respectivamente.

Después de utilizar el prototipo durante 1 año la variación en Ex_1 , Ex_2 , Ex_3 , Ex_4 respecto a los proyectos realizados el año anterior fue el mostrado en la Tabla 18. En la compañía existían 5 tipos de proyecto: servicios de despliegue de red, diseño y optimización de redes, consultoría e integración, soporte a clientes, así como sistema de gestión de clientes.

Parámetro	Total (%)	Servicios de despliegue de red (%)	Diseño y optimización de redes (%)	Consultoría e Integración (%)	Soporte a clientes (%)	Sistema de gestión de clientes (%)
Ex1	4,09%	3,26%	3,31%	4,92%	5,43%	3,53%
Ex2	4,12%	3,31%	3,62%	6,59%	5,62%	1,45%
Ex3	4,25%	3,99%	3,83%	5,79%	6,01%	1,63%
Ex4	3,43%	3,33%	2,28%	5,99%	4,39%	1,18%

Tabla 18. Incremento del porcentaje de proyectos que cumplen Ex_1 , Ex_2 , Ex_3 , Ex_4 comparados respecto a los realizados el año anterior, total y por área. (%i: % increase)

Se observa que, de modo general, aumentó el porcentaje de proyectos que cumplen con los criterios de éxito. La mejora más significativa ocurrió en los proyectos de las áreas de Consultoría e Integración (Ex_2 y Ex_4) y Soporte a clientes (Ex_1 y Ex_3). La mejora menos importante sucedió en los proyectos de los campos de Servicios de despliegue de red (Ex_1) y Sistema de gestión de clientes (Ex_2 , Ex_3 y Ex_4). En lo que respecta a los datos totales, el mayor y menor incremento tuvieron lugar en Ex_3 (4,25%) y Ex_4 (3,43%), respectivamente. Al finalizar el año se realizó una pequeña encuesta a todas las personas relacionadas con la solución e involucradas en el proceso de ventas (responsables de área comercial, especialistas contractuales, expertos técnicos). La encuesta contenía dos preguntas puntuables entre 1 (el peor valor) y 10 (el mejor valor):

- ¿La herramienta satisface tus necesidades?
- ¿Cree que la herramienta ha ayudado a mejorar los resultados del negocio?

La calificación media de la encuesta fue de 9,2.

6.- CONCLUSIONES E INVESTIGACIÓN FUTURA

La solución descrita estima si un proyecto TIC podría a priori cumplir con los criterios de éxito establecidos en la compañía (0 impactos no planificados, desvío de presupuesto [0,-4]%, desviación de fecha final [0, +2 semanas], calificación promedio en encuesta del cliente [7, 10]). Para ello considera características del proyecto relativas a complejidad, riesgo, tamaño y entorno.

La solución puede ser de utilidad a los miembros de las cuentas comerciales durante el proceso de ventas; quienes, si el proyecto no supera en un primer momento los criterios de éxito, podrían cambiar a través de la IU algunas de sus características (complejidad arquitectónica, número de sedes con interfaces de cliente independientes, tecnología, alcance, duración, etc.), realizando nuevas estimaciones hasta lograr su superación. Los resultados podrían ser manejados durante la etapa de negociación de la propuesta.

La estructura de las RNA, entre las analizadas, que permitió obtener los valores MSE más pequeños fue la constituida por una capa de entrada con 16 nodos, 3 capas ocultas con 11 nodos y una capa de salida con un nodo.

En las capas de entrada y salida se empleó la función Sigmoid. La función de activación en las capas ocultas que cumplió con los objetivos para el tiempo de entrenamiento así como para el MSE fue la Rectified Linear Unit. En el caso de Ex_1 , con un tiempo de entrenamiento medio de 1.43 horas esta función consiguió un MSE promedio de 0,00019 y de 0,00018, para los conjuntos de entrenamiento y prueba, con una tasa de aprendizaje de $\tau = 0,09652$. En lo que se refiere a Ex_2 , para un volumen del conjunto de entrenamiento de 390.690 y un tiempo de entrenamiento promedio de 1.20 horas logró un MSE medio de 0,00024 y de 0,00021, para los conjuntos de entrenamiento y prueba, con una tasa de aprendizaje de $\tau = 0,09543$. En lo que respecta a Ex_3 , para un conjunto de entrenamiento de tamaño 390.690 y un tiempo de entrenamiento medio de 1.43 horas obtuvo un MSE promedio igual a 0,00015 y 0,00014, para los conjuntos de entrenamiento y prueba, con una tasa de aprendizaje de $\tau = 0,09720$. En el caso de Ex_4 , con un tamaño del conjunto de entrenamiento de 390.690 y un tiempo de entrenamiento promedio de 1.43 horas, logró un MSE medio de 0,00023 y de 0,00021 para los conjuntos de entrenamiento y prueba, con una tasa de aprendizaje de $\tau = 0,09512$.

La solución fue valorada con una puntuación de 9,2 sobre 10 en una encuesta realizada a todas las personas relacionadas con la solución e implicadas en el proceso de ventas.

REFERENCIAS

- [1] Oludare IA, Aman JA, Esther O, Kemi VD, Nachaat AEM, Humaira A. "State-of-the-art in artificial neural network applications: A survey". Heliyon. Vol. 4-11, p. 217-225, 2018.
- [2] Fine TL. Feedforward Neural Network Methodology (Information Science and Statistics). New York. Springer, 2013. 340 p. ISBN: 9780387987453.
- [3] Nasr, M.B., Chtourou, M. 2006. "A Hybrid Training Algorithm for Feedforward Neural Networks". Neural Processing Letters. Vol 24-2 p. 107-117. DOI: <https://doi.org/10.1007/s11063-006-9013-x>.
- [4] Lee C, Chung P, Tsai J, Chang C. "Robust radial basis function neural networks". IEEE Transactions on Systems, Man, and Cybernetics, Part B: Cybernetics. Vol 29-6 p. 674-685, 1999.
- [5] Nong J. 2012. Radial Basis Function Neural Networks Optimization Algorithm Based on SVM. En: Zhao M., Sha J. (eds) Communications and Information Processing. Communications in Computer and Information Science, Vol. 289. Berlin: Springer, 2012. p. 291-298.
- [6] Ramchoun H, Amine M, Idrissi J, Ghanou I, Ettaouil M. "Multilayer perceptron: Architecture optimization and training". International Journal of Interactive Multimedia and Artificial Intelligence. Vol. 4-1 p. 26-30, 2016.
- [7] Yamashita R, Nishio M, Do RKG, Togashi K. "Convolutional neural networks: an overview and application in radiology". Insights Imaging. Vol. 9-4 p. 611-629, 2018.

- [8] Happel BLM, Murre, JMJ. "Design and evolution of modular neural network architectures". Neural Networks, Vol. 7, p. 985-1004, 1994.
- [9] Graves A, Fernández S, Gomez F, Schmidhuber J. "Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks". En ICML '06 Proceedings of the 23rd international conference on Machine learning. 1. Pittsburgh: Machinery, 2006, P. 369-376. ISBN: 9781595933836.
- [10] Sutskever I, Vinyals O, Le QV. "Sequence to sequence learning with neural networks". Advances in neural information processing systems. Vol. 9 p. 3104-3112, 2014.
- [11] Ilya S, Oriol V, Le Quoc V. "Sequence to sequence learning with neural networks", Advances in neural information processing systems. Vol. 2014 p. 3104-3112, 2014.
- [12] Jayne C, Iliadis L. Special issue: Engineering applications of neural networks. Neural Computing and Application, Vol. 29-7, p. 303-637, 2018.
- [13] Mossalam A, Arafa M. "Using artificial neural networks (ANN) in projects monitoring dashboards". HBRC Journal. Vol.14-3 p. 385-392, 2018.
- [14] Kim G, Seo D, Kang K. "Hybrid Models of Neural Networks and Genetic Algorithms for Predicting Preliminary Cost Estimates". Journal of Computing in Civil Engineering. Vol. 19-2, p. 208-211, 2005.
- [15] Wang X, Duan X, Liu J. "Application of Neural Network in the Cost Estimation of Highway Engineering". Journal of Computers. Vol. 5-11 p. 1762-1766, 2010.
- [16] Bayram S, Ocal M, Oral LE, Atis C. "Comparison of multi layer perceptron (MLP) and radial basis function (RBF) for construction cost estimation: the case of Turkey". Journal of Civil Engineering and Management, Vol. 22-4, p.480-490, 2015.
- [17] Sodikov J. "Cost estimation of highway projects in developing countries: artificial neural network approach". Journal of the Eastern Asia Society for Transportation Studies. Vol. 6 p. 1036 – 1047, 2005.
- [18] Petroutsatou, K. Georgopoulos, E, Lambropoulos, S. and Pantouvakis J. "Early Cost Estimating of Road Tunnel Construction Using Neural Networks". Journal of Construction Engineering and Management. Vol. 138-6 p. 679-687, 2012.
- [19] López-Martín C, Abran A. "Neural networks for predicting the duration of new software projects". Journal of Systems and Software. Vol. 101 p.127-135, 2015.
- [20] Gazder U, Shakshuki E, Adnan M, Yasar A. "Artificial Neural Network Model to relate Organization Characteristics and Construction Project Delivery Methods". Procedia Computer Science. Vol. 134, p. 59-66, 2018.
- [21] OnCheung S, PuiWong PS, Fung, ASY, Coffey WV. "Predicting project performance through neural networks". International Journal of Project Management. Vol. 24-3 p. 207-215, 2006.
- [22] Joosten D, Basten D, Mellis W. Measurement of Information System Project Success in Organizations - What Researchers Can Learn from Practice. En 19th European Conference on Information Systems, ECIS 2011. Helsinki: [s.n.], 2011.
- [23] Pollack J, Helm J, Adler D. "What is the Iron Triangle, and how has it changed?". International Journal of Managing Projects in Business", Vol. 11-2 p. 527-547, 2018.
- [24] Standish Group 2015 Chaos. <https://www.infoq.com/articles/standish-chaos-2015> [Accessed February 2020].
- [25] PMI. 2019. Project Management Institute. <https://www.pmi.org/> [Accessed February 2020].
- [26] Prince 2. 2019. <https://www.prince2.com/uk> [Accessed February 2020].
- [27] Agile. <https://www.agilealliance.org/agile2019/> [Accessed February 2020].
- [28] Mouronte-López, M L. "Optimizing the Spare Parts Management Process in a Communication Network". Journal of Network and Systems Management. Vol. 26-1 p. 169-188, 2017.
- [29] Mouronte-López, M. "An Automated Approach to Improve the Monitoring of Business Forecast Financial Compliance in the IT Industry". DYNA New Technologies. Vol. 6-1. p. 1-14, 2019. DOI: <http://dx.doi.org/10.6036>.
- [30] Rumelhart DE, Hinton GE, Williams R J. "Learning Representations By Back Propagating Errors". Nature, Vol. 323 p. 533-536, 1986.
- [31] Glorot X, Bengio, Y. "Understanding the difficulty of training Deep feedforward neural networks". En Proceedings of the thirteenth international conference on artificial intelligence and statistics. Sardinia: PMLR, 2010. P 249-256.
- [32] He, K, Zhang, X, Ren, S, Sun J. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. En Proceedings of the IEEE international conference on computer vision, Santiago de Chile: IEEE Computer Society, 2015. P. 1026-1034. ISBN: 9781467383912.
- [33] ORACLE. <http://www.oracle.com/es/index.html>. [Accessed February 2020].
- [34] PYTHON. <https://www.python.org/> [Accessed February 2020].
- [35] IBM MQ. <http://www-03.ibm.com/software/products/en/ibm-mq>. [Accessed 24 February 2020].